

Univerzita Karlova
Přírodovědecká fakulta

Studijní program:

Botanika – Geobotanika



Bc. Jakub Rataj

[[[nazev]]]

[[[nazev_AJ]]]

Typ závěrečné práce:

Diplomová práce

Vedoucí práce:

Mgr. Jan Smyčka PhD.

Praha, 2026

Prohlášení

[[[prohlaseni]]]

V Praze dne [[datum dokonceniiio]]

.....

Jakub Rataj

Poděkování

[[[podekovani]]]

Abstrakt

[[[abstrakt]]]

Klíčová slova: [[[klíčová slova]]]

Abstract

[[[abstract]]]

Keywords: [[[key words]]]

Přehled použitých zkratek

[[[seřadit podle abecedy]]] [[[převést na tabulku]]]

LGM – last glacial maximum, poslední glaciální maximum

HCO – holocene climatic optimum, holocénní klimatické optimum

DEM – digital elevation model, digitální model reliéfu

TPI

TRI

HLI

TWI

ESM – ensemble of small models

GLiM

SDM – species distribution modelling, modelování rozšíření druhů,
modelování rozšíření potenciálně vhodných stanovišť

EO, DPZ – Earth observing, dálkový průzkum Země

S-D – Somerovo D

GLM – generalized linear model, zobecněný lineární model

GBM – boosted regression trees

CTA – klasifikační stromy

RF – random forest

MARS – multivariate adaptive regression splines

GAM – generalized additive models, zobecněné aditivní modely

AUC – area under the receiver operating characteristic curve, plocha pod ROC křivkou

GPS –

CV –

Obsah

1. Úvod	1
1.1. x	1
1.2. Cíle práce	1
2. Metodika	2
2.1. Prostorové vymezení práce	2
2.2. Druhy Rostlin	2
2.3. Vstupní data	3
2.3.1. Data o výskytech druhů	3
2.3.1.1. Terénní sběr dat	3
2.3.1.2. Příprava výskytových dat	4
2.3.1.3. Prostorová autokorelace výskytových dat	4
2.3.2. Prediktory	5
2.3.2.1. Klimatické prediktory	5
2.3.2.2. Topografické prediktory	8
2.3.2.3. Horninový substrát	12
2.3.2.4. Půdní prediktory	12
2.3.2.5. Krajinný pokryv	13
2.4. Příprava dat	13
2.4.1. Datové sady pro modelování, kolinearita prediktorů	13
2.5. Modelování vhodnosti stanoviště	14
2.6. Projekce	17
2.6.1. Projekce v prostoru	17
2.6.2. Projekce v prostoru a čase	17
2.7. Metoda Shape jako odhad projekční extrpolace v prostoru	18
2.8. Prohlášení k metodám	18
3. Výsledky	20
4. Diskuse	21
5. Závěr	22
6. Literatura	23

1. Úvod

1.1. x

[[[proximita prediktorů]]]

Dalším důležitým prediktorem používaným v modelech rozšíření vhodných stanovišť je informace o geologickém podloží. Zohlednění substrátu přináší do modelu důležitou informaci, jelikož erozní procesy specifické pro daný horninový substrát přímo ovlivňují vlastnosti půdy. [[[citace? nebo obecná znalost?]]] Zejména u rostlin tak může zachycovat ekologické gradienty, které nejsou plně postižitelné klimatickými a topografickými proměnnými, přičemž zařazení geologického substrátu do modelu může zlepšit predikci rozšíření potenciálně vhodných stanovišť, obzvlášť v horských a geologicky heterogenních územích. (Dubuis et al., 2013; Chauvier et al., 2021)

Kromě samotného typu geologického podloží mohou být pro modelování rozšíření vhodných stanovišť významné také konkrétní půdní vlastnosti, které mají na růst rostlin přímější vliv. Ku příkladu hloubka půdy, půdní reakce a schopnost půdy zadržovat vodu ovlivňují přežívání rostlin významně silněji než samotný druh horniny. Zahrnutí prediktorů charakterizujících takové vlastnosti půdy může vysvětlovat část variability, kterou není možné zachytit pouze klasifikovaným geologickým substrátem, a vést k lepším projekcím vhodných stanovišť v prostoru. (Dubuis et al., 2013)

Z tohoto důvodu byly v této práci vedle geologické vrstvy GLiM využity také vybrané půdní prediktory ze systému SoilGrids, který poskytuje globální predikce půdních vlastností v prostorovém rozlišení 250 m založené na půdních pozorování a následném strojovém učení. (Hengl et al., 2017)

[[[povídání o tom, že půda se mění v čase a není možné tyto prediktory požívat při temporálních extrapolacích]]]

[[[povídání o nepřesnostech v prediktorových datasetech – interpolace viz soilgrids, chelsa a počet stanic meteo na Balkáně, NAOPAK přesnost DEM, EO dat]]]

[[[studium změny klimatu je důležité proč]]]

V odborné obci panuje obecná shoda, že probíhající globální klimatická změna může vést k elevačnímu posunu klimatických zón a návaznému zmenšení rozlohy (sub)alpínských biotopů. Taková změna by vedla k ohrožení druhů se slabou migrační schopností a druhů vyskytujících se v oblastech, kde již není možné migrovat do vyšších nadmořských výšek. (Climate Change (IPCC), 2023)

1.2. Cíle práce

2. Metodika

2.1. Prostorové vymezení práce

2.2. Druhy Rostlin

Gentiana tergestina Beck.

Gentiana tergestina je vytrvalá rostlina s nízkou, obvykle nevětvenou lodyhou zakončenou jedním sytě modrým květem. Listy jsou soustředěny především v přízemní růžici, lodyžní listy jsou menší a vyrůstají v 1-3 vstřícně uspořádaných párech (viz Obrázek 1 a). Druh se vyskytuje převážně na subalpinských a alpských loukách na vápenci. Těžiště rozšíření leží v horských oblastech Balkánského poloostrova, avšak druh je uváděn i mimo Balkán ze střední Itálie a Pyrenejí. (Josifović et al., 1973; Tutin a al, 1972) Přesné vymezení taxonu je dlouhodobě předmětem debat a v literatuře je možné se setkat i s označením *Gentiana verna* subsp. *tergestina*. Molekulární studie však naznačují, že jde o dobře vymezený druh. (Hämmerli, 2007; Smyčka et al., 2022)

Gentiana dinarica Beck.

Gentiana dinarica je vytrvalý zástupce rodu hořců (*Gentiana*) s přízemní růžicí široce eliptických listů a výraznými tmavě modrými trubkovitými květy (viz Obrázek 1 b). Ekologicky je vázána především na suché subalpinské a alpské louky na vápencovém podloží. Vyskytuje se v horách západního Balkánu, avšak podobně jako u *G. tergestina* se nejedná o čistě balkánský endemit, jelikož je jeho výskyt uváděn také ze střední Itálie a Pyrenejí. (Josifović et al., 1973; Tutin a al, 1972)

Phyteuma orbiculare L.

Phyteuma orbiculare je vytrvalá bylina, charakteristická jednoduchou lodyhou a kulovitým květenstvím tvořeným modrými až tmavě fialovými květy (viz Obrázek 1 f). Na rozdíl od balkánského druhu *P. pseudorbiculare* jde o širěji rozšířený evropský taxon. Ekologicky je spojen především s travinnými stanovišti, včetně subalpinských a alpských trávníků. (Tutin a al, 1976)

Phyteuma pseudorbiculare Pant.

Phyteuma pseudorbiculare je vytrvalý balkánský endemit příbuzný široce rozšířenému druhu *P. orbiculare* a sesterský druhu *P. sieberi* (Schneeweiss et al., 2013; Smyčka et al., 2022). Od druhu *P. orbiculare*, se kterým se vyskytuje v rámci Balkánského poloostrova na podobných lokalitách, se odlišuje mimo jiné tvarem listů a velmi krátkými, případně zcela chybějícími řapíky (viz Obrázek 1 g). Kvete sytě modrými květy a roste především na alpských pastvinách, na bázemi bohatém podloží. (Josifović et al., 1974; Tutin a al, 1976)


Primula kitaibeliana Schott

Primula kitaibeliana je vytrvalá rostlina z rodu prvosenek (*Primula*). Druh je endemický pro západní Balkán s disjunktním rozšířením v pohoří Velebit a v centrální části Bosny a Hercegoviny. Vytváří listovou růžici a krátkou lodyhu nesoucí růžové (viz Obrázek 1 c). Roste na kamenitých pastvinách a ve skalních štěrbinách, převážně na vápencovém podloží. (Zhang a Kadereit, 2004)

Saxifraga blavii Beck.

Saxifraga blavii je vytrvalá rostlina s obvykle větvenou lodyhou. Charakteristická je drobná

přízemní růžice a olistěná žlaznatě chlupatá lodyha nesoucí větší množství bílých květů. Listy jsou podlouhlé a bývají zakončené třemi špičkami (viz Obrázek 1 **d** & **e**). Druh je vázán na disturbovaná vysokohorská stanoviště, zejména skalky a sutě. Vyskytuje se výhradně v horách západního Balkánu. (Josifović et al., 1972; Tutin, 1964)



Obrázek 1: Studované druhy rostlin. **a:** *Gentiana tergestina* Beck., **b:** *Gentiana dinarica* Beck., **c:** *Primula kitaibeliana* Schott., **d** & **e:** *Saxifraga blavii* Beck., **f:** *Phyteuma orbiculare* L. & **g:** *Phyteuma pseudorbiculare* Pant.

Foto **c** převzato od Felix Puff, **e** & **f** od Jana Smyčky, **a**, **b**, **d** & **g** autor.

2.3. Vstupní data

2.3.1. Data o výskytech druhů

2.3.1.1. Terénní sběr dat

Terénní sběr výskytových dat probíhal na předem vybraných lokalitách, u nichž bylo na základě nadmořské výšky a charakteru prostředí předpokládáno zastoupení alpinské vegetace. Průzkum byl směřován především do horských oblastí nad 1700 metrů nad mořem. Jednotlivé trasy terénního průzkumu byly vedeny směrem k vrcholovým partiím a tak, aby co nejlépe pokrývaly variabilitu stanovištních podmínek, ideálně v severo-jížní orientaci. Při pohybu v terénu byly využívány zejména značené cesty, které umožňovaly lepší průchodnost terénem. Terénní práce probíhaly v letech 2020 – 2023.

Během průzkumu byly zaznamenávány presenční body nalezených fokálních druhů a v případě, že se studované druhy podél trasy nevyskytovaly, také body absenční. Poloha jednotlivých záznamů byla určena pomocí GPS v souřadnicovém systému WGS 84 (EPSG:4326). U každého záznamu byl kromě polohy zaznamenán identifikátor nálezu,

název druhu, stručný popis lokality a datum sběru. V okolí přibližně 30 m od každého nálezů byla kontrolována přítomnost dalších fokálních druhů a při jejich nalezení pro ně byly zaznamenány samostatné presenční body. V úsecích, kde druh souvisle pokrýval delší část trasy, byly body zapisovány přibližně po 100 m.

2.3.1.2. Příprava výskytových dat

Výskytová data byla před modelováním převedena do jednotné podoby a připravena samostatně pro jednotlivé modelované druhy. V prvním kroku byly sjednoceny názvy taxonů a odstraněny nekonzistence vzniklé při zápisu terénních dat, jako na příklad překlepy a observační body s evidentně chybným prostorovým zaměřením.

Pro každý fokální druh byla následně vytvořena samostatná vrstva obsahující všechny dostupné presence a absence, přičemž za absence daného druhu byly považovány globální absence (žádný z fokálních druhů se na lokalitě navyskytuje) a presence jiných druhů (na loklitě se vyskytuje druh X → absence pro všechny ostatní druhy).

K terénním datům byly u druhů *Gentiana tergestina* a *Primula kitaibeliana* připojeny také externí nálezové záznamy z *Flora Croatica Database* (Nikolić et al., 2026), které nesly pouze informaci o přítomnosti. Tyto záznamy byly proto do dat zahrnuty až později a výhradně jako presence. Z databáze byla vybrána pouze pozorování georeferencovaná podle GPS.

Takto sestavené datové sady byly následně porovnány s referenčními rastry prediktorů ve všech využitých prostorových rozlišeních. Na výskytová data byl aplikován filtr, jehož účelem bylo, aby pro každou buňku referenčního rastru, která se překrývá s výskytovými daty, byl zachován pouze jeden výskytový záznam. V případě, že do jedné buňky spadalo více observačních dat, byly před absencemi preferovány presence. Výsledkem byly sady výskytových dat ve stejném prostorovém rozlišení jako sady prediktorů a očištěné o nadbytečné absenční body (eventuelně očištěné i o body presenční, pokud spadalo více záznamů stejného druhu do identické rastrové buňky).

V dalším kroku byly jednotlivým pozorováním přiřazeny váhy, aby byla při modelování vyrovnána odlišná četnost presencí a absencí, zohledněn původ presenčních záznamů a také nejistota ohledně spolehlivosti absenčních bodů (např. přehlédnutí jedince) (Benkendorf et al., 2023). Celková váha byla rozdělena mezi presence a absence v poměru 1 : 1, takže obě třídy měly na fitování modelů stejný souhrnný vliv.

U presenčních záznamů byl dále zohledněn jejich zdroj (Fletcher Jr et al., 2019; Zhang et al., 2020). Presencím pocházejícím z provedených terénních prací byla přidělena oproti záznamům databázovým dvojnásobná váha. Důvodem k tomuto rozhodnutí byl předpoklad, že terénní sběr byl, na rozdíl od databázových položek, proveden přímo za účelem této práce a lokality byly vybírány tak, aby došlo k co možná nejlepšímu pokrytí studované oblasti. Databázová data byla naopak lokalizována výhradně na území Chorvatska a sbírána podle neznámé metodiky v odlišném časovém rozmezí.

2.3.1.3. Prostorová autokorelace výskytových dat

Pro hodnocení výkonu modelů byly připraveny prostorově oddělené křížově-validační soubory výskytových dat (také CV – cross-validační – foldy). Tento proces byl proveden

pro každou kombinaci druhu a prostorového rozlišení samostatně. Cílem tohoto dělení bylo omezit prostorovou autokorelaci výskytových dat a zamezit tak nadhodnocení predikční úspěšnosti. (Bahn a McGill, 2013; F. Dormann et al., 2007; Roberts et al., 2017)

Nejprve byla pomocí funkce *cv_spatial_autocor* z balíčku *blockCV* (Valavi et al., 2023) odhadnuta prostorová autokorelace výskytových dat. Na základě vypočteného dosahu byla stanovena velikost prostorových bloků. Tyto bloky byly následně přiřazeny do cross-validačních foldů pomocí iterativního náhodného rozdělování tak, aby počet výskytových záznamů byl mezi foldy co nejvíce vyvážen. Druhou důležitou podmínkou bylo, aby v každém foldu byly pro daný druh jak presenční, tak absenční záznamy. Aby byly podmínky obě podmínky vyváženosti splněny, byl konečný počet cross-validačních foldů pro každý druh optimalizován zvlášť.

2.3.2. Prediktory

V rámci této práce byly k trénování modelů rozšíření vhodných stanovišť využity prediktory z pěti základních skupin:

1. **klimatické** prediktory charakterizující na hrubém měřítku variabilitu teploty a srážek
2. **topografické** prediktory jejichž účelem je postihnout jemnější variabilitu mikrostanovištních podmínek
3. **horninový** substrát sloužící jako základní charakteristika geologických poměrů na regionální úrovni
4. **půdní** prediktory rozvíjejí informaci o půdních poměrech na úrovni lokalit a je možné považovat je za ekologicky relevantnější než samotný geologický substrát [[[zdroj]]]
5. **krajinný pokryv** klasifikuje povrch Země do základních formačních skupin a jako jediný prediktor přináší do modelů informaci, která je vzdáleně schopna charakterizovat biotické faktory [[[zdroj]]]

2.3.2.1. Klimatické prediktory

Jedním z důležitých metodických rozhodnutí při přípravě environmentálních prediktorů je volba klimatického datasetu pro současné, budoucí a historické projekce. Srovnávací studie ukazují, že teplotní proměnné klimatických datasetů jsou obvykle konzistentní, zejména díky silné vazbě teploty a nadmořské výšky. Výraznější rozdíly se však objevují u srážkových proměnných, jejichž prostorové rozložení je v horském prostředí ovlivněno lokální cirkulací vzduchu, která je pod rozlišovací schopností globálních klimatických modelů. (Bobrowski a Schickhoff, 2017; Fierke et al., 2024)

[[[možná do úvodu?? ↑↑↑]]]

Pro tuto práci byl zvolen dataset CHELSA (Brun et al., 2022a; Brun et al., 2022b), a to především kvůli jeho vhodnosti pro modelování v topograficky členitých oblastech. (Bobrowski a Schickhoff, 2017)

Dataset CHELSA-BIOCLIM je globální klimatický dataset s vysokým prostorovým rozlišením 30 úhlových sekund (cca 1 km²). Vychází z hrubších klimatických dat, která jsou zpřesněna pomocí topografických modelů, jejichž využití umožňuje kromě výpočtu vlivu nadmořské výšky i zohlednění topografické situace na proudění vzduchu. V této práci jsou využity bioklimatické charakteristiky podchycující roční a sezónní variabilitu klimatu v

prostoru (bio01-bio19). (Brun et al., 2022a) Do analýz navíc vstupoval i prediktor popisující počet dní v roce, kdy je na daném místě přítomna sněhová pokrývka (snow cover days, scd).

Tabulka 1: Přehled použitých bioklimatických prediktorů datasetů CHELSA-BIOCLIM a CHELSA-TraCE21k-bioclim.

Kód	Jednotky	Význam
bio01	°C	Průměrná roční teplota vypočítaná jako průměr průměrných měsíčních teplot za celý rok.
bio02	°C	Průměrný denní teplotní rozsah vypočítaný jako průměr měsíčních rozdílů mezi maximální a minimální denní teplotou (<i>tasmax</i> – <i>tasmin</i>).
bio03	°C	Isotermalita: $100 \times \text{bio02} / \text{bio07}$; porovnává denní teplotní variabilitu s ročním teplotním rozsahem.
bio04	°C/100	Teplotní sezonalita vyjádřená směrodatnou odchylkou průměrných měsíčních teplot.
bio05	°C	Nejvyšší měsíční průměr denních maximálních teplot (<i>tasmax</i>) v průběhu roku; vyjadřuje extrémní teplotní podmínky v nejteplejším období.
bio06	°C	Nejnižší měsíční průměr denních minimálních teplot (<i>tasmin</i>) v průběhu roku; charakterizuje intenzitu zimního chladu.
bio07	°C	Roční teplotní rozsah vypočítaný jako $\text{bio05} - \text{bio06}$; vyjadřuje rozdíl mezi nejteplejším a nejchladnějším měsícem.
bio08	°C	Průměrná měsíční teplota během nejvlhčího tříměsíčního období roku.
bio09	°C	Průměrná měsíční teplota během nejsuššího tříměsíčního období roku.
bio10	°C	Průměrná měsíční teplota během nejteplejšího tříměsíčního období roku.
bio11	°C	Průměrná měsíční teplota během nejchladnějšího tříměsíčního období roku.
bio12	$\text{kg } m^{-2} \text{rok}^{-1}$	Součet měsíčních úhrnů srážek za celý rok.
bio13	$\text{kg } m^{-2} \text{měsíc}^{-1}$	Nejvyšší měsíční úhrn srážek.
bio14	$\text{kg } m^{-2} \text{měsíc}^{-1}$	Nejnižší měsíční úhrn srážek.
bio15	$\text{kg } m^{-2}$	Koeficient variability měsíčních úhrnů srážek vypočítaný jako $100 \times \text{směrodatná odchylka} / \text{průměr}$.
bio16	$\text{kg } m^{-2} \text{měsíc}^{-1}$	Průměrný měsíční úhrn srážek během nejvlhčího tříměsíčního období roku.
bio17	$\text{kg } m^{-2} \text{měsíc}^{-1}$	Průměrný měsíční úhrn srážek během nejsuššího tříměsíčního období roku.
bio18	$\text{kg } m^{-2} \text{měsíc}^{-1}$	Průměrný měsíční úhrn srážek během nejteplejšího tříměsíčního období roku.
bio19	$\text{kg } m^{-2} \text{měsíc}^{-1}$	Průměrný měsíční úhrn srážek během nejchladnějšího tříměsíčního období roku.
scd	dny	Počet dní v roce, kdy je na zemském povrchu přítomna sněhová pokrývka.

Kromě charakterizace současného klimatu poskytuje dataset CHELSA-BIOCLIM i pro tři časové řezy (2011–2040, 2041–2070 & 2071–2100) modely extrapolující klima do budoucnosti (tzv. earth system models: GFDL-ESM4, IPSL-CM6A-LR, MPI-ESM 1-2-HR, MRI-ESM2-0, & UKESM1-0-LL) na základě různých emisních scénářů (shared socioeconomic pathways: ssp126, ssp370 & ssp585 (O'Neill et al., 2016)).

[[[citovat earth system modely nebo vynechat podle toho, který nakonec půjde ven]]]

S ohledem na zachování metodické konzistence mezi jednotlivými časovými řezy byl pro projekci modelů na historické klimatické podmínky použit dataset CHELSA-TraCE21k-bioclim (Karger et al., 2020; Karger et al., 2023), který poskytuje klimatické rekonstrukce od posledního glaciálního maxima po současnost v časových krocích 100 let a prostorovém rozlišení 30 úhlových sekund (cca 1 km²).

Klimatické prediktory byly před vstupem do modelů prostorově sjednoceny s ostatními rastrovými vrstvami. Nejprve byly reprojektovány do souřadnicového systému ETRS89-extended / LAEA Europe (EPSG:3035) a zarovnány na referenční rastr odpovídající nejhrubšímu použitému prostorovému rozlišení 1000 m, přičemž byla použita metoda nejbližšího souseda, aby nedocházelo k interpolaci. Takto připravené vrstvy byly následně převedeny do jemnějších modelovacích rozlišení tak, že každá jemnější dceřinná buňka přebírala hodnotu příslušné mateřské buňky. Tento postup zachoval původní informační obsah klimatických dat a zároveň umožnil jejich kombinaci s prediktory dostupnými v jemnějších prostorových rozlišeních.

2.3.2.2. Topografické prediktory

Pro analýzu topografie byl v této práci použit globální elevační dataset *Copernicus DEM 30* s prostorovým rozlišením 30 m². (European Space Agency a Airbus, 2022) Tento model je odvozen z dat mise dálkového průzkumu Země TanDEM-X a poskytuje tak nejpřesnější prostorové i absolutní zaměření poměrů na daných lokalitách mezi prediktory využitými v této práci.

Data byla získána prostřednictvím prostorového požadavku ve službě Copernicus Data Space Ecosystem (D. Kovács et al., 2026) zprostředkovaného *openEO* klientem v prostředí R. (Lahn, 2026) Stažené rastrové dlaždice byly následně sloučeny do mozaiky, reprojektovány do souřadnicového systému ETRS89-extended / LAEA Europe (EPSG: 3035) a maskovány polygonem zájmového území.

Topografické prediktory využitě v této práci lze rozdělit do dvou skupin podle toho, jak popisují prostorové fenomény. První skupina charakterizuje vztah cílové buňky k jejímu okolí pomocí pohyblivého okna 3*3 buňky, tedy lokální topografický kontext. Druhá skupina popisuje vnitřní elevační variabilitu dané buňky při převodu z jemnějšího na hrubší prostorové měřítko. Přehled topografických prediktorů viz Tabulka 2.

Pro první skupinu byl nejprve vytvořen DEM odpovídajícího měřítka pomocí agregace původních dat *Copernicus DEM 30*. Hodnoty byly agregovány podle mediánu. Z takto vzniklého modelu byly pomocí *terra::terrain()* (Hijmans et al., 2026) vypočteny vrstvy *slope*, *aspect*, *TPI*, *TRI*, *TRIriley*, *TRIrmsd*, *roughness* a *flowdir*. *TPI* vyjadřuje rozdíl mezi výškou středové buňky a průměrem okolních buněk (Weiss, 2001). Kladné hodnoty indexu

značí lokálně vyvýšené pozice, například hřbety, a záporné hodnoty lokální sníženiny. Hodnoty okolo nuly představují plochý terén. *TRI* průměr absolutních výškových rozdílů mezi středovou buňkou a okolím a *roughness* rozdíl mezi maximální a minimální hodnotou v rámci pohyblivého okna. Prediktory *TRI_riley* & *TRI_rmsd* jsou deriváty jednoduššího *TRI* snažící se lépe zachytit elevační variabilitu v geomorfologicky členitých oblastech. Jde o odmocninu součtu čtvercových rozdílů (*TRI_riley*, (Riley et al., 1999)) a o odmocninu průměru čtvercových rozdílů (*TRI_rmsd*, (Wilson et al., 2007)).

Tato skupina topografických prediktorů byla následně rozšířena o prediktory *eastness* a *northness* odvozené z orientace svahu (*aspect*) jako sinus, respektive kosinus orientace svahu převedené na radiány. Tyto proměnné vyjadřují východo-západní a severo-jihní složky orientace svahu. V navazujících modelech byly použity jako zástupné prediktory za *aspect* samotný, jelikož tento prediktor vykazuje kruhový charakter ($360^\circ = 0^\circ$) a není vhodný pro běžné algoritmy (Wilson et al., 2007). Dalším rozšířením je *HLI* (heat load index, (McCune a Keon, 2002)), který byl vypočten funkcí *spatialEco::hli()* (Evans a Murphy, 2021). Tato metrika vyjadřuje potenciální teplotní zatížení svahu a kombinuje informaci o sklonu (*slope*) a aspektu (*aspect*), přičemž hodnoty se pohybují od chladnějších po teplejší lokality. (McCune a Keon, 2002) Posledním prediktorem počítaným pomocí pohyblivého okna byl *TWI* (topographic wetness index, (Beven a Kirkby, 1979)), který byl vypočítán na základě směru odtoku (*flowdir*), akumulované přispívající ploše (lokální „povodí“) a sklonu (*slope*) v radiánech. Výsledný index byl vypočten jako logaritmus poměru specifické přispívající plochy a tangens sklonu.

Druhá skupina zahrnuje prediktory vzniklé během agregace jemných základních dat *Copernicus DEM 30* do hrubšího prostorového měřítka. Z originálních dat byly – kromě *dem_median*, který sloužil jako podklad prediktorů první skupiny – během agregace vypočteny proměnné *dem_sd* (směrodatná odchylka nadmořských výšek), *dem_min* (minimální nadmořská výška), *dem_max* (maximální nadmořská výška) & *dem_range* (rozdíl mezi maximální a minimální nadmořskou výškou). Tyto prediktory tak nezachycují topografický kontext lokality, ale heterogenitu reliéfu uvnitř jedné modelovací buňky.

Tabulka 2: Přehled topografických prediktorů odvozených z digitálního modelu reliéfu DEM. Ve vzorcích z_0 reprezentuje elevaci buňky, pro kterou je daný parametr počítán, z_i ukazuje na sousední buňky v rámci pohyblivého okna a z_j se vztahuje k buňkám, které byly agregovány do menšího rozlišení.

Zkratka	Název	Jednotky	Způsob výpočtu	Popis výpočtu	Citace
Relativní topografické prediktory					
Prediktory počítané z DEM v cílovém rozlišení: popisují vztah středové buňky k okolním buňkám v rámci pohyblivého okna.					
aspect	<i>Aspect</i>	stupně	<i>terra::terrain</i>	Orientace svahu odvozená z relativní elevace okolních buňek.	Hijmans et al. (2026), Horn (2005)
slope	<i>Slope</i>	stupně	<i>terra::terrain</i>	Sklon povrchu odvozený z relativní elevace okolních buňek.	Hijmans et al. (2026), Horn (2005)
eastness	<i>Eastness</i>	–	$\sin(\text{aspect})$	Sinus aspektu v radiánech; vyjadřuje východo-západní složku orientace svahu.	–
northness	<i>Northness</i>	–	$\cos(\text{aspect})$	Kosinus aspektu v radiánech; vyjadřuje severo-jihní složku orientace svahu.	–
HLI	<i>Heat Load Index</i>	–	<i>spatialEco::hli</i>	Index potenciálního teplotního zatížení svahu odvozený ze sklonu, orientace a zeměpisné šířky.	Evans a Murphy (2021), McCune a Keon (2002)
flowdir	<i>Flow direction</i>	–	<i>terra::terrain</i>	Směr odtoku určený podle sousední buňky s nejmenší elevací.	Hijmans et al. (2026)
TWI	<i>Topographic Wetness Index</i>	–	$\ln\left(\frac{a}{\tan(\beta)}\right)$	Logaritmický poměr specifické přispívající plochy a a sklonu svahu β ; vyšší hodnoty indikují potenciálně vlhčí místa.	Beven a Kirkby (1979)
TPI	<i>Topographic Position Index</i>	metry	$z_0 - \frac{1}{8} \sum_{i=1}^8 z_i$	Rozdíl mezi výškou středové buňky a průměrnou výškou okolních buněk.	Hijmans et al. (2026), Weiss (2001), Wilson et al. (2007)

Zkratka	Název	Jednotky	Způsob výpočtu	Popis výpočtu	Citace
roughness	<i>Roughness</i>	metry	$\max(z_0, z_i) - \min(z_0, z_i)$	Rozdíl mezi nejvyšší a nejnižší hodnotou výšky v rámci pohyblivého okna.	Hijmans et al. (2026), Wilson et al. (2007)
TRI	<i>Terrain Ruggedness Index</i>	metry	$(\frac{1}{n}) \sum_i z_0 - z_i $ <i>terra::terrain</i>	Průměr absolutních výškových rozdílů mezi středovou buňkou a okolím.	Hijmans et al. (2026), Wilson et al. (2007)
TRI_riley	<i>Terrain Ruggedness Index – Riley</i>	metry	$\sqrt{\sum_i (z_0 - z_i)^2}$ <i>terra::terrain</i>	Odmocnina ze součtu čtvercových výškových rozdílů mezi středovou buňkou a okolními buňkami.	Hijmans et al. (2026), Riley et al. (1999)
TRI_rmsd	<i>Terrain Ruggedness Index – RMSD</i>	metry	$\sqrt{(\frac{1}{n}) \sum_i (z_0 - z_i)^2}$ <i>terra::terrain</i>	Odmocnina z průměru čtvercových výškových rozdílů mezi středovou buňkou a okolními buňkami.	Hijmans et al. (2026), Wilson et al. (2007)

Agregační topografické prediktory

Prediktory vzniklé během agregace originálních dat do cílového rozlišení: popisují elevační variabilitu uvnitř jedné modelovací buňky.

dem_median	<i>Median elevation</i>	metry	$\text{median}(z_j)$	Medián elevací 30m buněk agregovaných do jedné buňky cílového rozlišení.	–
dem_sd	<i>Elevation standard deviation</i>	metry	$\text{sd}(z_j)$	Směrodatná odchylka elevací 30m buněk agregovaných do jedné buňky cílového rozlišení.	–
dem_max	<i>Maximum elevation</i>	metry	$\max(z_j)$	Maximální elevace 30m buněk agregovaných do jedné buňky cílového rozlišení.	–
dem_min	<i>Minimum elevation</i>	metry	$\min(z_j)$	Minimální elevace 30m buněk agregovaných do jedné buňky cílového rozlišení.	–
dem_range	<i>Elevation range</i>	metry	$\max(z_j) - \min(z_j)$	Rozdíl mezi maximální a minimální elevací 30m buněk agregovaných do jedné buňky cílového rozlišení.	–

2.3.2.3. Horninový substrát

Geologické podloží je v této práci reprezentováno vrstvou GLiM (Global Lithological Map, (Hartmann a Moosdorf, 2012)). Tento projekt poskytuje globální vektorovou mapu pevninských geologických jednotek. Pro spolehlivější pokrytí jednotlivých skupin hornin výskytovými daty byla vrstva nejprve reklasifikována do 3 tříd: *karbonátové*, *silikátové* a *smíšené* podloží (viz Tabulka 3). Reklasifikace proběhla po vzoru práce Chauvier et al. (2021). V druhém kroku byla reklasifikovaná vrstva rasterizována podle centroidu do všech využitých rozlišení buňek s využitím souřadnicového systému ETRS89-extended / LAEA Europe (EPSG: 3035).

Tabulka 3: Přehled reklasifikace geologického podloží.

Kategorie použité v této práci podle Chauvier et al. (2021)	Původní kategorie GLiM podle Hartmann a Moosdorf (2012)
Calcareous <i>karbonáty</i>	Carbonate sedimentary rocks Basic plutonic rocks Basic volcanic rocks
Siliceous <i>silikáty</i>	Siliciclastic sedimentary rocks Metamorphic rocks Acid plutonic rocks Acid volcanic rocks
Mixed <i>smíšené</i>	Unconsolidated sediments Mixed sedimentary rocks Pyroclastics Evaporites Intermediate plutonic rocks Intermediate volcanic rocks

2.3.2.4. Půdní prediktory

Pro doplnění prediktorové sádky o informaci o půdních poměrech byly použity tři vrstvy z databáze *SoilGrids250m* (Hengl et al., 2017). Konkrétně šlo o absolutní hloubku k podloží (*absolute depth to bedrock*), udávanou v centimetrech, dostupnou vodní kapacitu do bodu vadnutí (*derived available soil water capacity until wilting point*), vyjádřenou jako objemový podíl, a půdní reakci měřenou ve vodě (*soil pH in H₂O*), zapsanou jako pH*10.

Originální rastrová data byla prostorově sjednocena s referenčními rastry, avšak vzhledem k tomu, že jsou poskytována v hrubším měřítku, než nejjemnější měřítko využitě v této práci, byla data pro rozlišení 100 a 200 m interpolována pomocí bilineární funkce. V případě agregace originálních dat do rozlišení 500 a 1000 m byl vypočítán průměr hodnot původních buňek. V rámci zmíněných operací byla data projektována do souřadnicového systému ETRS89-extended / LAEA Europe (EPSG: 3035).

Vzhledem k tomu, že půdní charakteristiky jsou v čase relativně dynamické, byly tyto prediktory využity pouze k trénování modelů, jejichž účelem nebylo extrapolovat rozšíření vhodných stanovišť do historických podmínek, případně do budoucnosti, ale pouze charakterizovat co nejvěrněji současné rozšíření.

2.3.2.5. Krajinný pokryv

Krajinný pokryv je v této práci reprezentován datasetem ESA WorldCover 2021. Tato data představují globální klasifikaci zemského povrchu v prostorovém rozlišení 10 m založenou na snímcích družic Sentinel-1 a Sentinel-2 (Zanaga et al., 2022). Dataset byl v této práci použit jako kategorický prediktor zachycující současný biotopový stav lokalit.

Data byla ručně stažena na základě prostorového dotazu z oficiálních stránek projektu. Připravené dlaždice byly nejprve sloučeny do jedné mozaiky, oříznuty a maskovány polygonem studovaného území a následně reprojektovány do souřadnicového systému ETRS89-extended / LAEA Europe (EPSG: 3035). Základní vrstva byla dále informovaně agregována do rozlišení 100, 200, 500 a 1000 m podle modální hodnoty, přičemž byla zvýhodňována kategorie *bare/sparse vegetation*: v případě, že v buňce cílového rozlišení činil podíl této kategorie alespoň 5 %, byla celá buňka klasifikována jako *bare/sparse vegetation*. Tento postup měl omezit ztrátu prostorově málo rozsáhlých, avšak pro horské druhy potenciálně významných otevřených stanovišť při převodu do hrubšího rozlišení.

[[[kategorie LC]]]

Podobně jako DEM je i vrstva kategorizovaného krajinného pokryvu založená na datech dálkového průzkumu Země a jde tudíž o prostorově velmi přesný produkt s poměrně vysokou rozlišovací přesností. Určitou nevýhodou pro využití v SDM je – podobně jako u půdních prediktorů – nepřenositelnost v čase. Z tohoto důvodu nebyl krajinný pokryv zařazen do modelů určených pro temporální extrapolaci.

2.4. Příprava dat

2.4.1. Datové sady pro modelování, kolinearita prediktorů

Před samotným modelováním byly pro všechny environmentální prediktory upraveny prostorové parametry tak, aby výsledné vrstvy byly prostorově jednotné. Jednotlivé vrstvy prediktorů byly zarovnány na společné referenční rastry, reprojektovány do souřadnicového systému ETRS89-extended / LAEA Europe (EPSG: 3035) a maskovány podle polygonu studovaného území. Prediktory byly podle typu dat převzorkovány nebo agregovány do prostorových rozlišení využitých v této práci, čímž vznikla sada vzájemně kompatibilních rastrových vrstev pro modelovací měřítka 100, 200, 500 a 1000 m.

Z takto připravených vrstev byly následně vytvořeny výchozí rastrové soubory (stacks) obsahující všechny kandidátní environmentální prediktory dostupné pro dané prostorové rozlišení. Pro účely temporálních projekcí byla navíc připravena užší varianta prediktorových souborů, ze které byly vyloučeny prediktory reprezentující v čase proměnlivé fenomény a tudíž nevhodné pro extrapolaci mimo současnost (krajinný pokryv a pedologické vrstvy).

Na připravených souborech byla následně posouzena kolinearita prediktorů. Hodnoty prediktorů byly extrahovány pro tuto analýzu extrahovány dvojím způsobem: (i) z buňek pozorování jednotlivých druhů a (ii) v náhodně vybraném vzorku 50 tisíců buněk studovaného území. Dichotomie tohoto vzorkování měla v prvním případě předejít kolinearitě v datech, která přímo vstupují do modelu a ve druhém případě obecně

kolinearitě, kterou by kvůli specifickým podmínkám vzorkovaných lokalit neodhalil přístup první.

Pro každý druh a každé prostorové rozlišení byl na extrahovaných vzorcích proveden poloautomatizovaný výběr proměnných s využitím balíčku *collinear* (Benito, 2025). V rámci procesu byla kolinearita posuzována pomocí párové Pearsnovy korelace a podle faktoru inflace variance (VIF, variance inflation factor). Prahová hodnota maximální povolené korelace byla stanovena na $r = 0.7$ a maximální VIF = 7 (Dormann et al., 2013). Výsledky byly vizualizovány pomocí balíčku *corrplot* (Wei et al., 2017).

Automatizované rozhodování mezi kolineárními prediktory bylo doplněno předem stanoveným prioritním pořadím proměnných. Účelem tohoto pořadí bylo prioritizovat ekologicky relevantní prediktory a naopak upozadit prediktory s relativně komplikovanou interpretovatelností (Dormann et al., 2013; Soley-Guardia et al., 2024) a evidentními artefakty (např. CHELSA-BIOCLIM: bio08, bio9 mají v oblasti Balkánského poloostrova velmi ostré prostorové přechody mezi hodnotami, které – dle soukromé úvahy autora – nemohou mít fyzikální opodstatnění).

Varianta	Preferenční pořadí prediktorů	Vyloučené prediktory
Bez temporální extrapolace	<i>bio06, bio05, bio10, bio11, scd, landcover, northness, bio14, bio12, HLI, TWI, dem_range, dem_sd, slope, TPI, TRI, TRI_riley, TRI_rmsd, bio18, bio19, bio04, bio01, bedrock, eastness, dem_median, aspect, depth_to_bedrock, pH_in_H2O, soil_water_cap, bio02, bio03, bio15</i>	<i>bio08, bio09, flowdir</i>
Temporální extrapolace	<i>bio10, bio11, northness, scd, bio06, bio05, dem_sd, dem_range, TPI, TRI, TRI_riley, TRI_rmsd, bio18, bio19, bio04, bio01, slope, eastness, bedrock, dem_median, aspect, bio02, bio03, bio15</i>	<i>bio08, bio09, landcover, pH_in_H2O, HLI, soil_water_cap, depth_to_bedrock, TWI, flowdir</i>

Výsledkem filtrace byly dvě sady prediktorů pro každý druh. První sada zahrnovala všechny prediktory vybrané analýzou kolinearity, přičemž byl brán zřetel pouze na kolineární strukturu v dané kombinaci druh-prostorové rozlišení. Druhá sada byla omezena pouze na prediktory, které byly pro daný druh vybrány konzistentně napříč všemi prostorovými rozlišeními. Tato druhá společná sada umožnila srovnávat modely mezi různými prostorovými rozlišeními buňek, tj. modely trénované na stejné prediktorové sadě, avšak s jiným rozlišením. [[]]

Takto vytvořené soubory prediktorů posloužily přímo jako vstupní data do navazujících analýz, tedy do samotného procesu modelování rozšíření vhodných stanovišť.

2.5. Modelování vhodnosti stanoviště

Modely druhového rozšíření byly vytvářeny metodou ensemble of small models (ESM) podle metodiky Breiner et al. (2015). Tento přístup byl zvolen kvůli relativně malému počtu pozorování modelovaných druhů a současně potřebě pracovat s větším množstvím

environmentálních prediktorů. Vytvoření jednoho komplexního modelu obsahujícího všechny prediktory současně by v takové situaci mohlo vést k overfittingu. Metoda ESM tomuto riziku předchází tak, že namísto jednoho komplexního modelu vytváří všechny možné kombinace jednoduchých bivariátních modelů, které jsou testovány samostatně (Breiner et al., 2015; Lomba et al., 2010).

Modelování probíhalo samostatně pro jednotlivé druhy a pro jednotlivá prostorová rozlišení prediktorů. Nejprve byly k bodovým výskytovým datům přiřazeny hodnoty všech prediktorů z příslušného souboru prediktorů. Každý záznam tak obsahoval informaci o presenci nebo absenci druhu, koordináty, váhu observace a hodnoty environmentálních prediktorů. Záznamy, pro které nebyla dostupná hodnota některého z použitých prediktorů, byly vyloučeny. Kategorické prediktory byly pro účely modelování převedeny na faktory.

Samotný modelovací proces začal vytvořením všech dostupných bivariátních kombinací pro každý použitý algoritmus:

$$N_{\text{modelů}} = N_{\text{biv. kombinací prediktorů}} \times N_{\text{algoritmů}}$$

Pro všechny rostlinné druhy a pro všechna rozlišení prediktorů bo použito těchto 6 algoritmů: zobecněné lineární modely (*GLM*, R Core Team (2026)), boosted regression trees (*GBM*, Ridgeway et al. (2013)), zobecněné aditivní modely (*GAM*, Wood a Wood (2015)), klasifikační stromy (*CTA*, Therneau et al. (2015)), multivariate adaptive regression splines (*MARS*, Milborrow (2019)) a random forest (*RF*, Wright et al. (2019)).

Jednotlivé bivariátní modely byly trénovány na předem připravených prostorových podmnožinách (CV fold, viz Kapitola 2.3.1.3 [[[kapitola??]]] Obrázek 2) observačních dat, kde část dat byla použita k fitování modelu a část k jeho testování. Výsledky této křížové validace byly pro každou jednu podmnožinu kvantifikovány pomocí Somersova D (dále také jako *S-D*, Harrell Jr (2019); Somers (1962)).

$$\text{Somersovo D} = 2 \times (\text{AUC} - 0.5)$$

Tato metrika vychází z běžně používaného AUC (*area under the receiver operating characteristic curve*), nabývá hodnot od -1 do 1 a vyjadřuje diskriminační schopnost modelu, kde kladné hodnoty značí lepší než náhodné rozlišení presencí a absencí, zatímco nulové nebo záporné hodnoty ukazují na model s horší rozlišovací schopností než model náhodný.

V dalším kroku byly hodnoty Somersova D pro daný bivariátní model zprůměrovány a podrobeny porovnání s hraniční hodnotou 0. Bivariátní modely s průměrným $S-D \leq 0$ byly z dalších analýz vyloučeny.


Z bivariátních modelů, které prošly sítí, byl sestaven algoritmický soubor predikcí (*algo-ESM*, viz Obrázek 2), přičemž příspěvek jednotlivých bivariátních modelů byl vážen jejich průměrným výkonem. Modely s vyšší hodnotou *S-D* tak měly v *algo-ESM* větší vliv než modely s nižší, avšak stále kladnou úspěšností. Soubor predikcí byl sestaven pro každý algoritmus samostatně.

Predikce takto sestavených algo-ESM byla následně znovu vyhodnocena podle testovacích částí předpřipravených CV foldů a analogicky jako v kroku výše bylo vypočteno průměrné Somerovo D pro daný algo-ESM a porovnáno s hraniční hodnotou, přičemž algo-ESM s průměrným $S-D \leq 0$ byly z dalších analýz opět vyloučeny. Pokud v tomto kroku nastala situace, že $S-D_{\text{algo-ESM}} \leq 0$, došlo v daném běhu k efektivnímu vyloučení celé větve algoritmu z modelovacího procesu.

Po dokončení validačního procesu byly ponechané bivariátní modely znovu trénovány na celém dostupném datasetu. Tento krok zajistil, že finální ESM model využíval pro odhad vztahu mezi výskytem druhu a prostředím všechna cenná dostupná data. Relativní příspěvky jednotlivých bivariátních modelů natrénovaných na celém datasetu byly váženy přes váhy získané v prvním kroku sestavování algo-ESM a zároveň přes váhu algoritmu jako celku. Efektivní příspěvek bivariátního modelu je možné vyjádřit jako:

$$w_{\text{efektivní}} = w_{\text{bivariátní model}} \times w_{\text{mateřský algo-ESM}}$$

kde $w_{\text{efektivní}}$ vyjadřuje intenzitu příspěvku bivariátního modelu do celkového ESM, $w_{\text{bivariátní model}}$ vyjadřuje váhu daného bivariátního modelu mezi všemi ostatními bivariátními modely stejného algoritmu a $w_{\text{mateřský algo-ESM}}$ vyjadřuje váhu celého algoritmu.



Obrázek 2: Schematické znázornění modelovacího procesu ESM.

2.6. Projekce

2.6.1. Projekce v prostoru

2.6.2. Projekce v prostoru a čase

[[[co ta budoucí projekce]]]


Vypočítané modely byly promítnuty do dvou historických a jednoho budoucího časového řezu. [[[]]] Jako reprezentativní body v minulosti byly vybrány dva časové řezy: poslední glaciální maximum (LGM, 21k BP) a holocénní klimatické optimum (HCO, 8k BP).

Jelikož se v obou případech jedná o sporné vymezení konkrétních událostí (např. Davis et al. (2003) ukazují, že HCO se v jižní Evropě neprojevovalo tak silně jako v Evropě severní), je nutné vnímat zvolené časové řezy jako částečně arbitrární rozhodnutí.

2.7. Metoda Shape jako odhad projekční extrapolace v prostoru

Metoda Shape (Velazco et al., 2024) představuje nástroj určený k posouzení míry extrapolace při prostorové či časové projekci modelů vhodnosti stanoviště. Jejím principem je porovnání podmínek prostředí v projekční oblasti s podmínkami, na jejichž základě byl model kalibrován.

Pro každou rastrovou buňku, je v mnohorozměrném environmentálním prostoru vypočítána Mahalanobisova vzdálenost ke každému bodu z trénovací sady a z této množiny je pro daný bod vybrána ta nejnižší (Obrázek 3 (a)). Takto vypočtená vzdálenost je následně škálována disperzním faktorem trénovacích dat, čímž vzniká bezrozměrná metrika vyjadřující míru environmentální novosti dané lokality (Obrázek 3 (b)). Nízké hodnoty metriky Shape odpovídají podmínkám blízkým trénovacím datům, a tedy lokalitám, kde model interpoluje v rámci známého environmentálního prostoru. Oproti tomu vysoké hodnoty ukazují, že projekce je prováděna do podmínek, které nejsou v trénovacích datech výrazněji zastoupeny, a predikce v daných lokalitách je proto zatížena vyšší nejistotou.



Obrázek 3: Grafické znázornění metody Shape v zjednodušeném dvourozměrném prostoru. (a) Reprezentuje výpočet Mahalanobisových vzdáleností mezi projekčním bodem a všemi trénovacími body. Nejnižší vzdálenost vyznačena oranžově. (b) Vyjádření metriky Shape S_{pi} pro projekční body. A značí disperzní faktor trénovacích dat. Vyšší hodnota S_{pi} značí vyšší míru environmentální novosti a tudíž vyšší míru extrapolace modelu. Převzato z Velazco et al. (2024)

[[[realizace Shape v diplomce]]]

2.8. Prohlášení k metodám

Veškeré analýzy byly provedeny v prostředí R, verze 4.2.2 – Innocent and Trusting (R Core Team, 2026) s využitím těchto balíčků: *terra*, *sf*, *tidyverse*, *maptiles*, *blockCV*, *openeo*,

collinear, corrplot, rnaturalearth, flexsdm, foreach, doParallel, parallelly, Hmisc, gbm, mgcv, rpart, earth, ranger, maps & spatialEco.

Vizualizace a kontrola výstupních rastrů probíhala v programu QGIS, verze 3.28.9 – Firenze (QGIS Development Team, 2026).

Část výpočtů byla provedena s využitím výpočetních zdrojů MetaCentra.

Computational resources were provided by the e-INFRA CZ project (ID:90254), supported by the Ministry of Education, Youth and Sports of the Czech Republic.

Prohlašuji, že při přípravě předložené práce byly použity následující nástroje AI uvedenými způsoby:

ChatGPT v období **1. 11. 2025 – 7. 8. 2026**, popis použití: generování kódu k analýze dat, generování kódu využitého k sazbě práce, vyhledávání publikací a zpracování výtahů z nich, návrhy textů.

Po použití uvedených nástrojů umělé inteligence jsem důkladně revidoval a upravil obsah podle potřeby a plně přejímám odpovědnost za výslednou podobu práce.

Skripty využité v rámci této diplomové práce jsou dohledatelné ve veřejném repozitáři na GitHub na adrese <https://github.com/zbubster/Western-Balkans-SDM-thesis>.

[[[vytvořit release a odkazovat na něj]]]]

3. Výsledky

4. Diskuse

V této práci byla z důvodu metodické konzistence zvolena jednotná datová sada CHELSA-BIOCLIM (Brun et al., 2022b) & CHELSA-TraCE21k (Karger et al., 2020) pro současné, budoucí i historické projekce. Tento přístup zajišťuje srovnatelnost mezi jednotlivými časovými řezy, avšak nezachycuje nejistotu spojenou s volbou klimatického datasetu. V oblastech s vyšší geomorfologickou členitostí je přesnost klimatických modelů sporná a volba konkrétního klimatického datasetu ovlivňuje výsledné křivky odpovědi druhů na konkrétní environmentální faktory i rozlohu a rozmístění modelem predikovaných vhodných stanovišť (Morales-Barbero a Vega-Álvarez, 2019) Pro vyšší důvěryhodnost projekcí je proto vhodné pracovat s více klimatickými modely a jednotlivé výsledky mezi sebou porovnávat.

Dalším problematickým aspektem globálních klimatických modelů jsou extrapolace klimatu do historických období. Rentier et al. (2025) ukázali, že rekonstrukce ekologických fenoménů na základě klimatických projekcí se silně odlišují mezi jednotlivými datasety i mezi rekonstrukcemi založenými na proxy ukazatelích, přičemž slabší výsledky se projevovaly u klimatických datasetů s hrubším měřítkem. Chybovost klimatických modelů navíc vykazovala obecný trend k vyšším teplotám během LGM, obzvláště v horských oblastech. (Rentier et al., 2025) Dataset CHELSA-TraCE21k ve zmíněné studii vykazoval v horských oblastech nejhorší výsledky, a to pravděpodobně kvůli nadprůměrně složitému procesu interpolace a zjemňování originálních dat z meteorologických stanic, který v případě odlehlých horských oblastí vytvářel za velké množství statistického šumu s

Volba klimatického datasetu je tedy klíčová pro důvěryhodné modely současného a rekonstrukci historického rozšíření vhodných stanovišť.

V současné době je největší limitace datovými podklady, statistiku máme dostatečnou. Prediktorové sady vykazují značnou chybovost, obzvláště v odlehlých oblastech. Geologické i půdní mapy jsou taky surově interpolované a založené na omezeném počtu pozorování. Nabízenou cestou jsou data z dálkového průzkumu Země, která se výše zmíněným nedostatkům vyhýbají: jsou měřena „přímo“ na lokalitě, mají solidní časovou řadu a nadstandardní prostorové rozlišení. Na druhou stranu jsou produkty DPZ hůře ekologicky interpretovatelné a jejich zpracování vyžaduje vyšší nároky na výpočetní výkon.

Ačkoliv využití DPZ jako prediktorů v SDM je v současnosti zkoumáno a dosavadní výsledky ukazují na sporné vylepšení modelů, v jiných oblastech monitoringu přírody a krajiny nastává jejich rozvoj. Příkladem může být efektivní monitorování sucha a požárů,

Modely je obecně potřeba interpretovat s opatrností.

5. Závěr

6. Literatura

Bahn, V. a McGill, B. J.: Testing the predictive performance of distribution models, *Oikos*, 122, 321–331, 2013.

Benito, B. M.: collinear: R Package for Automated Multicollinearity Management, <https://doi.org/10.5281/zenodo.10039396>, 2025.

Benkendorf, D. J., Schwartz, S. D., Cutler, D. R., a Hawkins, C. P.: Correcting for the effects of class imbalance improves the performance of machine-learning based species distribution models, *Ecological Modelling*, 483, 110414, 2023.

Beven, K. J. a Kirkby, M. J.: A physically based, variable contributing area model of basin hydrology/Un modèle à base physique de zone d'appel variable de l'hydrologie du bassin versant, *Hydrological sciences journal*, 24, 43–69, 1979.

Bobrowski, M. a Schickhoff, U.: Why input matters: Selection of climate data sets for modelling the potential distribution of a treeline species in the Himalayan region, *Ecological Modelling*, 359, 92–102, <https://doi.org/https://doi.org/10.1016/j.ecolmodel.2017.05.021>, 2017.

Breiner, F. T., Guisan, A., Bergamini, A., a Nobis, M. P.: Overcoming limitations of modelling rare species by using ensembles of small models, *Methods in Ecology and Evolution*, 6, 1210–1218, 2015.

Brun, P., Zimmermann, N. E., Hari, C., Pellissier, L., a Karger, D. N.: Global climate-related predictors at kilometer resolution for the past and future, *Earth System Science Data*, 14, 5573–5603, <https://doi.org/10.5194/essd-14-5573-2022>, 2022a.

Brun, P., Zimmermann, N. E., Hari, C., Pellissier, L., a Karger, D. N.: CHELSA-BIOCLIM+ A novel set of global climate-related predictors at kilometre-resolution, 2022b.

Climate Change (IPCC), I. P. on: Mountains, in: *Climate Change 2022 – Impacts, Adaptation and Vulnerability: Working Group II Contribution to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change*, Cambridge University Press, 2273–2318, 2023.

D. Kovács, D., Musial, J., Bojanowski, J., Clarijs, D., Mar, J. de la, a Zlinszky, A.: Copernicus Data Space Ecosystem establishes public cloud processing for earth observation data, *Scientific Data*, 2026.

Davis, B., Brewer, S., Stevenson, A., a Guiot, J.: The temperature of Europe during the Holocene reconstructed from pollen data, *Quaternary Science Reviews*, 22, 1701–1716, [https://doi.org/https://doi.org/10.1016/S0277-3791\(03\)00173-2](https://doi.org/https://doi.org/10.1016/S0277-3791(03)00173-2), 2003.

Dormann, C. F., Elith, J., Bacher, S., Buchmann, C., Carl, G., Carré, G., Marquéz, J. R. G., Gruber, B., Lafourcade, B., Leitao, P. J., a others: Collinearity: a review of methods to deal with it and a simulation study evaluating their performance, *Ecography*, 36, 27–46, 2013.

Dubuis, A., Giovanettina, S., Pellissier, L., Pottier, J., Vittoz, P., a Guisan, A.: Improving the prediction of plant species distribution and community composition by adding edaphic to

topo-climatic variables, *Journal of Vegetation Science*, 24, 593–606, <https://doi.org/https://doi.org/10.1111/jvs.12002>, 2013.

European Space Agency a Airbus: Copernicus DEM, <https://doi.org/10.5270/ESA-c5d3d65>, 2022.

Evans, J. S. a Murphy, M. A.: *spatialEco*, 2021.

F. Dormann, C., M. McPherson, J., B. Araújo, M., Bivand, R., Bolliger, J., Carl, G., G. Davies, R., Hirzel, A., Jetz, W., Daniel Kissling, W., a others: Methods to account for spatial autocorrelation in the analysis of species distributional data: a review, *Ecography*, 30, 609–628, 2007.

Fierke, J., Joelson, N. Z., Loguercio, G. A., Putzenlechner, B., Simon, A., Wyss, D., Kappas, M., a Walentowski, H.: Assessing uncertainty in bioclimatic modelling: a comparison of two high-resolution climate datasets in northern Patagonia, *Regional Environmental Change*, 24, 110, 2024.

Fletcher Jr, R. J., Hefley, T. J., Robertson, E. P., Zuckerberg, B., McCleery, R. A., a Dorazio, R. M.: A practical guide for combining data to model species distributions, *Ecology*, 100, e02710, 2019.

Hämmerli, M.: Molecular aspects in systematics of “*Gentiana*” sect. “*Calathianae*” Froel., 2007.

Harrell Jr, M. F. E., Frank E: Package ‘*hmisc*’, CRAN2018, 2019, 235–236, 2019.

Hartmann, J. a Moosdorf, N.: The new global lithological map database GLiM: A representation of rock properties at the Earth surface, *Geochemistry, Geophysics, Geosystems*, 13, , <https://doi.org/https://doi.org/10.1029/2012GC004370>, 2012.

Hengl, T., Jesus, J. Mendes de, Heuvelink, G. B., Ruiperez Gonzalez, M., Kilibarda, M., Blagotić, A., Shangguan, W., Wright, M. N., Geng, X., Bauer-Marschallinger, B., a others: SoilGrids250m: Global gridded soil information based on machine learning, *PLoS one*, 12, e0169748, 2017.

Hijmans, R. J., Brown, A., a Barbosa, M.: *terra: Spatial Data Analysis*, 2026.

Horn, B. K.: Hill shading and the reflectance map, *Proceedings of the IEEE*, 69, 14–47, 2005.

Chauvier, Y., Thuiller, W., Brun, P., Lavergne, S., Descombes, P., Karger, D. N., Renaud, J., a Zimmermann, N. E.: Influence of climate, soil, and land cover on plant species distribution in the European Alps, *Ecological monographs*, 91, e01433, 2021.

Josifović, M., Stjepanović, L., Kojić, M., a Diklić, N.: *Flora SR Srbije 4*, SANU, Odeljenje prirodno-matematičkih nauka, 1972.

Josifović, M., Stjepanović, L., Kojić, M., a Diklić, N.: *Flora SR Srbije 5*, SANU, Odeljenje prirodno-matematičkih nauka, 1973.

Josifović, M., Stjepanović, L., Kojić, M., a Diklić, N.: *Flora SR Srbije 6*, SANU, Odeljenje prirodno-matematičkih nauka, 1974.

- Karger, D. N., Nobis, M. P., Normand, S., Graham, C. H., a Zimmermann, N. E.: CHELSA-TraCE21k: Downscaled transient temperature and precipitation data since the last glacial maximum, <https://doi.org/http://dx.doi.org/10.16904/envidat.211>, 2020.
- Karger, D. N., Nobis, M. P., Normand, S., Graham, C. H., a Zimmermann, N. E.: CHELSA-TraCE21k – high-resolution (1 km) downscaled transient temperature and precipitation data since the Last Glacial Maximum, *Climate of the Past*, 19, 439–456, <https://doi.org/10.5194/cp-19-439-2023>, 2023.
- Lahn, F.: openeo: Client Interface for 'openEO' Servers,, 2026.
- Lomba, A., Pellissier, L., Randin, C., Vicente, J., Moreira, F., Honrado, J., a Guisan, A.: Overcoming the rare species modelling paradox: A novel hierarchical framework applied to an Iberian endemic plant, *Biological conservation*, 143, 2647–2657, 2010.
- McCune, B. a Keon, D.: Equations for potential annual direct incident radiation and heat load, *Journal of Vegetation Science*, 13, 603–606, <https://doi.org/https://doi.org/10.1111/j.1654-1103.2002.tb02087.x>, 2002.
- Milborrow, M. S.: Package ‘earth’, R Software package, 2019.
- Morales-Barbero, J. a Vega-Álvarez, J.: Input matters matter: Bioclimatic consistency to map more reliable species distribution models, *Methods in Ecology and Evolution*, 10, 212–224, <https://doi.org/https://doi.org/10.1111/2041-210X.13124>, 2019.
- Nikolić, T., Bogdanović, S., Vuković, N., a Šegota, V. (Ed.): *Flora Croatica Database*, 2026.
- O'Neill, B. C., Tebaldi, C., Vuuren, D. P. van, Eyring, V., Friedlingstein, P., Hurtt, G., Knutti, R., Kriegler, E., Lamarque, J.-F., Lowe, J., Meehl, G. A., Moss, R., Riahi, K., a Sanderson, B. M.: The Scenario Model Intercomparison Project (ScenarioMIP) for CMIP6, *Geoscientific Model Development*, 9, 3461–3482, <https://doi.org/10.5194/gmd-9-3461-2016>, 2016.
- QGIS Development Team: QGIS Geographic Information System,, 2026.
- R Core Team: R: A Language and Environment for Statistical Computing,, 2026.
- Rentier, E. S., Mottl, O., Pacheco-Riaño, L. C., Schultz, L., Seguinot, J., Wiersma, A. T., Grytnes, J.-A., a Flantua, S. G. A.: Global variability in LGM cooling amongst paleoclimate datasets affects biome reconstructions in mountains, *Frontiers of Biogeography*, 18, e135871, <https://doi.org/10.21425/fob.18.135871>, 2025.
- Ridgeway, G., Southworth, M. H., a RUnit, S.: Package ‘gbm’, *Viitattu*, 10, 40, 2013.
- Riley, S. J., DeGloria, S. D., a Elliot, R.: Index that quantifies topographic heterogeneity, *intermountain Journal of sciences*, 5, 23–27, 1999.
- Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillerá-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., a Dormann, C. F.: Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure, *Ecography*, 40, 913–929, <https://doi.org/https://doi.org/10.1111/ecog.02881>, 2017.

- Schneeweiss, G. M., Pachschröll, C., Tribsch, A., Schönswetter, P., Barfuss, M. H., Esfeld, K., Weiss-Schneeweiss, H., a Thiv, M.: Molecular phylogenetic analyses identify Alpine differentiation and dysploid chromosome number changes as major forces for the evolution of the European endemic *Phyteuma* (Campanulaceae), *Molecular phylogenetics and evolution*, 69, 634–652, 2013.
- Smyčka, J., Roquet, C., Boleda, M., Alberti, A., Boyer, F., Douzet, R., Perrier, C., Rome, M., Valay, J.-G., Denoeud, F., a others: Tempo and drivers of plant diversification in the European mountain system, *Nature Communications*, 13, 2750, 2022.
- Soley-Guardia, M., Alvarado-Serrano, D. F., a Anderson, R. P.: Top ten hazards to avoid when modeling species distributions: a didactic guide of assumptions, problems, and recommendations, *Ecography*, 2024, e06852, <https://doi.org/https://doi.org/10.1111/ecog.06852>, 2024.
- Somers, R. H.: A New Asymmetric Measure of Association for Ordinal Variables, *American Sociological Review*, 27, 799–811, 1962.
- Therneau, T., Atkinson, B., Ripley, B., a Ripley, M. B.: Package ‘rpart’, Available online: [cran.ma.ic.ac.uk/web/packages/rpart/rpart.pdf](https://cran.r-project.org/web/packages/rpart/rpart.pdf) (accessed on 20 April 2016), 2, 5–32, 2015.
- Tutin, T. a al, et al et: *Flora Europaea*. Volume 3. Diapensiaceae to Myoporaceae., 1972.
- Tutin, T. G.: *Flora Europaea*. Vol. 1. Lycopodiaceae to Platana-ceae., 1964.
- Tutin, T. G. a al, et al et: *Flora Europaea*. Volume 4. Plantaginaceae to Compositae (and Rubiaceae)., 1976.
- Valavi, R., Elith, J., Lahoz-Monfort, J., Flint, I., a Guillera-Arroita, G.: Package ‘blockCV’, 2023.
- Velazco, S. J. E., Rose, M. B., De Marco Jr, P., Regan, H. M., a Franklin, J.: How far can I extrapolate my species distribution model? Exploring shape, a novel method, *Ecography*, 2024, e06992, <https://doi.org/https://doi.org/10.1111/ecog.06992>, 2024.
- Wei, T., Simko, V., Levy, M., Xie, Y., Jin, Y., Zemla, J., a others: Package ‘corrplot’, *Statistician*, 56, e24, 2017.
- Weiss, A.: Topographic position and landforms analysis, in: Poster presentation, ESRI user conference, San Diego, CA, 2001, 2001.
- Wilson, M. F., O’Connell, B., Brown, C., Guinan, J. C., a Grehan, A. J.: Multiscale terrain analysis of multibeam bathymetry data for habitat mapping on the continental slope, *Marine Geodesy*, 30, 3–35, 2007.
- Wood, S. a Wood, M. S.: Package ‘mgcv’, R package version, 1, 729, 2015.
- Wright, M. N., Wager, S., Probst, P., a Wright, M. M. N.: Package ‘ranger’, Version 0.11, 2, 2019.
- Zanaga, D., Van De Kerchove, R., Daems, D., De Keersmaecker, W., Brockmann, C., Kirches, G., Wevers, J., Cartus, O., Santoro, M., Fritz, S., Lesiv, M., Herold, M., Tsendbazar, N.-E.,

Xu, P., Ramoino, F., a Arino, O.: ESA WorldCover 10 m 2021 v200, <https://doi.org/10.5281/zenodo.7254221>, 2022.

Zhang, L.-B. a Kadereit, J. W.: Classification of *Primula* sect. *Auricula* (Primulaceae) based on two molecular data sets (ITS, AFLPs), morphology and geographical distribution, *Botanical Journal of the Linnean Society*, 146, 1–26, 2004.

Zhang, Z., Mammola, S., a Zhang, H.: Does weighting presence records improve the performance of species distribution models? A test using fish larval stages in the Yangtze Estuary, *Science of the Total Environment*, 741, 140393, 2020.